



UNIVERSIDADE PRESBITERIANA MACKENZIE

PROJETO APLICADO III

Tecnologia em Ciência de Dados

Desenvolvimento de um Sistema de Recomendação de Restaurantes Baseado em Dados da Plataforma iFood

Membros do Grupo:

Fernando da Silva Cordeiro de Lima - RA: 10424794

Clayton dos Santos Lira - RA: 10416054

Bruna Mendes Rocha – RA: 10441296

São Paulo 2025

Sumário

1. Introdução

- 1.1. Contexto do Trabalho
- 1.2. Motivação
- 1.3. Justificativa
- 1.4. Objetivo Geral

2. Referencial Teórico

- 2.1 Abordagens Fundamentais e Suas Limitações
- 2.2 Sistemas Híbridos e Arquiteturas Modernas
- 2.3 A Fronteira da Recomendação: Grafos de Conhecimento e LLMs
- 2.4 Avaliação Holística: Métricas Além da Acurácia

3. Metodologia

- 3.1 Definição do Problema e Objetivos
- 3.2 Coleta de Dados
- 3.3 Pré-processamento e Limpeza dos Dados
- 3.4 Divisão dos Dados
- 3.5 Seleção e Implementação do Algoritmo
- 3.6 Treinamento do Modelo
- 3.7 Avaliação do Desempenho
- 3.8 Otimização e Ajustes
- 3.9 Implantação e Monitoramento

4. Resultados e Discussão

- 4.1 Eficácia do Pré-processamento
- 4.2 Análise de Caso de Recomendação
- 4.2 Pontos Positivos e Limitações Observadas

5. Conclusão e Trabalhos Futuros

- 5.1 Conclusões
- 5.2 Trabalhos Futuros

1 – Introdução

1.1 Contexto do Trabalho

O crescimento exponencial das plataformas de delivery de comida, como o iFood, transformou a maneira como os consumidores escolhem suas refeições. No entanto, a vasta quantidade de opções disponíveis pode levar à "paralisia da escolha", onde o usuário se sente sobrecarregado e tem dificuldade em tomar uma decisão. Nesse cenário, os sistemas de recomendação surgem como uma ferramenta essencial para personalizar a experiência do usuário, sugerindo restaurantes e pratos alinhados às suas preferências individuais.

1.2 Motivação

A principal motivação para este projeto é aplicar técnicas de Machine Learning para solucionar um problema real e cotidiano, melhorando a experiência do usuário em uma das maiores plataformas de delivery do Brasil.

1.3 Justificativa

A justificativa se baseia em:

Relevância para o Consumidor: Ajudar os usuários a descobrir novos restaurantes e pratos de forma mais eficiente, otimizando o tempo de decisão e a satisfação com a escolha. Isso reduz a "paralisia da escolha" e melhora a experiência geral do usuário na plataforma.

Relevância para os Restaurantes: Aumentar a visibilidade de estabelecimentos, especialmente os menores ou mais novos, para o público certo, impulsionando o crescimento econômico local. Um sistema de recomendação eficaz pode direcionar clientes para restaurantes que, de outra forma, teriam dificuldade em se destacar em um mercado competitivo.

1.4 Objetivo Geral

O objetivo geral determina onde se espera chegar com a pesquisa.

- **Desenvolver** *um protótipo que* seja capaz de recomendar restaurantes da plataforma iFood, utilizando a base de dados pública "iFood Restaurants Data" do Kaggle.

Os objetivos específicos detalham o objetivo geral e apresentam a sequência lógica para alcançá-lo:

- **Analisar** *como* a base de dados selecionada se estrutura e *quais* etapas de pré-processamento são necessárias.
- **Implementar** *um modelo que* utilize uma abordagem híbrida, combinando filtragem colaborativa e filtragem baseada em conteúdo.
- **Avaliar** *se* o desempenho do modelo é eficaz, utilizando métricas apropriadas [ex: precisão, recall, RMSE].
- **Descrever** *como* todas as etapas do desenvolvimento foram executadas, desde a concepção até a análise dos resultados.

Objetivo Extensionista

Este projeto, ao otimizar a conexão entre consumidores e restaurantes e promover escolhas

mais eficientes, contribui indiretamente para diversos Objetivos de Desenvolvimento Sustentável (ODS) da ONU, com potencial para impactos mais diretos em futuras iterações:

ODS 8: Trabalho Decente e Crescimento Econômico

- **Promoção do Crescimento Econômico Inclusivo:** O sistema de recomendação atua como um catalisador para o crescimento econômico ao dar maior visibilidade a uma gama diversificada de restaurantes, incluindo pequenos e médios empreendimentos que, de outra forma, poderiam ter dificuldade em competir com grandes redes. Ao direcionar clientes para esses estabelecimentos, o sistema impulsiona suas vendas e faturamento.
- **Geração de Emprego e Renda:** O aumento da demanda e do volume de negócios para os restaurantes, facilitado pelas recomendações, pode levar à necessidade de mais mão de obra. Isso se traduz em criação de novos postos de trabalho (cozinheiros, entregadores, atendentes) e na garantia de renda para os já existentes, contribuindo para a redução do desemprego e a melhoria das condições de vida dos trabalhadores do setor.
- **Aumento da Produtividade e Eficiência:** Ao otimizar a correspondência entre a oferta de restaurantes e a demanda dos consumidores, o sistema de recomendação contribui para uma maior eficiência do mercado. Restaurantes podem gerenciar melhor seus estoques e sua produção ao ter um fluxo de clientes mais previsível, e os consumidores encontram o que desejam mais rapidamente.
- **Fortalecimento do Empreendedorismo Local:** O projeto incentiva o empreendedorismo ao oferecer uma plataforma mais equitativa para que novos negócios e restaurantes de nicho alcancem seu público.

ODS 12: Consumo e Produção Responsáveis

- **Impacto:** Embora o foco inicial seja a recomendação baseada em preferências, um sistema eficaz pode, a longo prazo, influenciar padrões de consumo. Ao guiar o usuário para escolhas mais assertivas, reduz-se a probabilidade de pedidos insatisfatórios que resultariam em desperdício de alimentos.
- **Expansões Futuras:** A inclusão de atributos relacionados à sustentabilidade (restaurantes com práticas de redução de desperdício, uso de ingredientes locais, embalagens sustentáveis) poderia diretamente promover um consumo mais responsável.
- **Exemplo:** Se o sistema puder, no futuro, recomendar restaurantes que utilizam ingredientes orgânicos ou que têm programas de doação de excedentes, ele estaria ativamente incentivando práticas de produção e consumo mais sustentáveis.

Potencial para ODS 2: Fome Zero e Agricultura Sustentável (em futuras iterações)

- **Impacto:** Embora não seja um objetivo direto desta fase, um sistema de recomendação de alimentos pode ser adaptado para identificar e promover o consumo de produtores locais, fortalecer cadeias de suprimentos sustentáveis e, indiretamente, contribuir para a segurança alimentar.

2 – Referencial Teórico

Sistemas de Recomendação (SRs) consolidaram-se como ferramentas essenciais em plataformas digitais, como o iFood, para mitigar a "paralisia da escolha" causada pela sobrecarga de informação. Ao personalizar a experiência do usuário, os SRs não apenas aumentam a satisfação do consumidor, mas também geram valor para os restaurantes ao aumentar sua visibilidade, alinhando-se a objetivos de crescimento econômico inclusivo (ODS 8) e consumo responsável (ODS 12).

2.1. Abordagens Fundamentais e Suas Limitações

A base dos sistemas de recomendação modernos reside em duas abordagens clássicas: a Filtragem Colaborativa (FC) e a Filtragem Baseada em Conteúdo (FBC).

Filtragem Colaborativa: Opera sob o princípio da "sabedoria da multidão", recomendando itens com base nas preferências de usuários com gostos similares, conforme definido nos manuais clássicos da área (RICCI; ROKACH; SHAPIRA, 2011). Contudo, sua principal desvantagem é o problema do início frio (cold start), que a impede de fazer recomendações precisas para novos usuários ou novos itens por falta de dados de interação. Esse desafio permanece atual, motivando o desenvolvimento de novas técnicas para mitigar a escassez de dados históricos (AGGARWAL, 2016; YANG et al., 2025).

Filtragem Baseada em Conteúdo: Recomenda itens com base em suas características intrínsecas (ex: categoria, preço, tags), sugerindo opções similares às que o usuário já demonstrou interesse (AGGARWAL, 2016). Embora eficaz para novos itens, essa abordagem pode levar à superespecialização. O foco excessivo na similaridade cria "bolhas de filtro" (filter bubbles) que limitam a descoberta de novas opções e reduzem a diversidade das sugestões, um tema crítico na discussão ética e funcional dos sistemas atuais (JANNACH et al., 2025).

2.2. Sistemas Híbridos e Arquiteturas Modernas

Para superar as limitações das abordagens clássicas isoladas, os Sistemas Híbridos surgiram como a solução padrão, combinando múltiplas técnicas para obter recomendações mais robustas e precisas, conforme estabelecido no trabalho seminal de Burke (2002).

A prática atual da indústria e da academia evoluiu para arquiteturas de múltiplos estágios, integrando dados multimodais e conhecimento externo. Essas arquiteturas são comumente divididas em fases distintas para lidar com a escala e a complexidade dos dados (ZHANG et al., 2025):

Geração de Candidatos (Retrieval): Algoritmos eficientes filtram o vasto catálogo para selecionar uma lista inicial de itens relevantes. Técnicas modernas têm aprimorado essa etapa utilizando Knowledge-Guided Retrieval para lidar melhor com contextos complexos (YANG et al., 2025).

Ranqueamento (Ranking): Modelos mais complexos reordenam essa lista curta para apresentar os melhores resultados. Atualmente, abordagens avançadas incorporam Grafos de Conhecimento e Grandes Modelos de Linguagem (LLMs) para refinar essa personalização e capturar nuances nas necessidades do usuário (CHEN et al., 2023; MOHBAT; ZAKI, 2025).

2.3. A Fronteira da Recomendação: Grafos de Conhecimento e LLMs

A pesquisa de vanguarda tem se concentrado em representações de dados mais ricas para capturar a complexidade das interações.

Grafos de Conhecimento (Knowledge Graphs - KGs) modelam usuários, itens e seus atributos como uma rede de entidades e relações. Essa estrutura permite descobrir conexões latentes e é especialmente eficaz para mitigar o problema do cold start. Modelos de Linguagem de Grande Porte (LLMs) representam a fronteira mais recente. Frameworks de ponta como o PIGEON (2025)

usam LLMs para prever "necessidades de vida" contextuais do usuário, indo além da simples correspondência de preferências (LAN et al., 2025).

2.4 REFERÊNCIAS BIBLIOGRÁFICAS

AGGARWAL, C. C. Recommender Systems: The Textbook. Cham: Springer, 2016.

BURKE, R. Hybrid recommender systems: Survey and experiments. User Modeling and User-Adapted Interaction, v. 12, n. 4, p. 331-370, 2002.

CHEN, Y. et al. Health-Aware Food Recommendation Based on Knowledge Graph and Multi-Task Learning. Foods, v. 12, n. 10, p. 2079, 2023.

JANNACH, D. et al. Recommender Systems for Good (RS4Good): Survey of Use Cases and a Call to Action for Research that Matters. ACM Transactions on Recommender Systems, no prelo, 2025.

LAN, T. et al. PIGEON: Predicting Open-Set Living Needs with Large Language Models. In: FINDINGS OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS: ACL 2025, Bangkok, Thailand, 2025. Anais [...]. Stroudsburg, PA: Association for Computational Linguistics, 2025.

MOHBAT, F.; ZAKI, M. J. KERL: Knowledge-Enhanced Personalized Recipe Recommendation using Large Language Models. In: PROCEEDINGS OF THE 63RD ANNUAL MEETING OF THE ASSOCIATION FOR COMPUTATIONAL LINGUISTICS, Bangkok, Thailand, 2025. Anais [...]. Stroudsburg, PA: Association for Computational Linguistics, 2025. p. 19125–19141.


RICCI, F.; ROKACH, L.; SHAPIRA, B. (Eds.). Recommender Systems Handbook. New York: Springer, 2011.

YANG, W. et al. Cold-Start Recommendation with Knowledge-Guided Retrieval-Augmented Generation. arXiv preprint arXiv:2505.20773, 2025.

ZHANG, Y. et al. A Survey on Multimodal Recommender Systems: A Technical Perspective. arXiv preprint arXiv:2502.15711, 2025.

3 – Metodologia

A organização sistemática e a descrição das técnicas utilizadas compõem esta Seção de metodologia. A metodologia aplicada neste projeto segue um fluxo estruturado que abrange todas as etapas do desenvolvimento do sistema de recomendação.



3.1 Definição do Problema e Objetivos Nesta etapa, definiu-se de forma clara o problema a ser abordado. O objetivo foi definir claramente o problema de escolha dos restaurantes e a solução proposta, que é a implementação de um sistema de recomendação híbrido.

3.2 Coleta de Dados A coleta foi realizada através do dataset 'iFood Restaurants Data' disponível no Kaggle. Este projeto utiliza dois *datasets* principais obtidos da plataforma Kaggle:

- **ifood-restaurants-enriquecido.csv**
Contém informações detalhadas sobre 406.399 registros de restaurantes, incluindo colunas como *category*, *delivery_fee*, *delivery_time*, *distance*, *price_range*, *rating* e *tags*.
- **users_data.csv:**
Contém informações sobre perfis de usuários e suas preferências declaradas.

3.3 Pré-processamento e Limpeza dos Dados A fase de diagnóstico inicial revelou problemas de qualidade nos dados que exigiram um tratamento rigoroso. As principais etapas de pré-processamento aplicadas foram:

- **Tratamento da Coluna *rating*:** A coluna de avaliação continha valores corrompidos e fora do intervalo esperado (0 a 5). Esses valores inválidos foram convertidos para NaN.
- **Limpeza da Coluna *tags*:** A coluna de palavras-chave era uma única *string* desorganizada. Foi aplicado um processo de limpeza para remover códigos, caracteres especiais e *stopwords*, resultando em uma nova coluna (*tags_final*).
- **Remoção de Colunas Irrelevantes:** Variáveis como *url* e *avatar* foram identificadas como sem valor preditivo e removidas.
- **Agrupamento de Categorias:** Categorias muito específicas (e.g., "Hamburguers") foram agrupadas em ("Lanches"). Categorias com menos de 100 restaurantes foram agrupadas em "outros".
- **Enriquecimento de Dados:** A coluna *ibge* (código numérico) foi unida a um *dataset* do IBGE para adicionar o nome da cidade a cada restaurante.

3.4 Divisão dos Dados A base de dados foi dividida em dois conjuntos: treinamento (80%) e teste (20%). A divisão foi feita de maneira a garantir que o conjunto de teste representasse situações reais.

3.5 Seleção e Implementação do Algoritmo O modelo híbrido foi implementado combinando **Filtragem Baseada em Conteúdo (CBF)** e **Filtragem Colaborativa (CF)**.

- Recomenda itens com base nas características dos próprios itens. A similaridade entre os restaurantes é calculada utilizando a Similaridade de Cosseno. A fórmula para calcular a similaridade entre dois restaurantes **A** e **B** é:

$$\text{sim}(A, B) = (A \cdot B) / (||A|| ||B||)$$

- **Filtragem Colaborativa (CF):** Utiliza o comportamento de outros usuários para prever quais itens um usuário pode gostar.

- **Sistema Híbrido:** Combina a CBF e CF para superar as limitações de cada técnica. A combinação ponderada é dada pela fórmula:

$$\hat{r}_{u,i}^{\text{hybrid}} = w1 \cdot \hat{r}_{u,i}^{\text{CBF}} + w2 \cdot \hat{r}_{u,i}^{\text{CF}} \text{ Onde } w1 \text{ e } w2$$

A arquitetura do sistema segue os seguintes passos:

1. **Criação de Perfis de Restaurantes:** Cada restaurante é transformado em um vetor numérico. *OneHotEncoder* é utilizado para colunas categóricas, *MultiLabelBinarizer* é usado para as *tags*, e *MinMaxScaler* é aplicado a colunas numéricas.
2. **Criação de Perfis de Usuários:** Perfis de usuários são criados com base em suas preferências declaradas e vetorizadas de forma compatível.
3. **Cálculo de Similaridade:** A **similaridade de cosseno** é calculada entre o vetor de perfil de um usuário e os vetores de perfil de todos os restaurantes para gerar as recomendações.

3.6 Treinamento do Modelo O modelo foi treinado com o conjunto de dados de treinamento, ajustando os parâmetros para melhorar a acurácia das recomendações. Foi dada maior ênfase na avaliação das preferências dos usuários e características dos restaurantes.

3.7 Avaliação do Desempenho O desempenho foi avaliado utilizando **métricas de precisão (Precision@k)**, **revocação (Recall@k)** e **F1-Score**, além de métricas como **Erro Médio Absoluto (MAE)** e **Raiz do Erro Quadrático Médio (RMSE)**, para garantir que o modelo estivesse gerando recomendações de qualidade.

3.8 Otimização e Ajustes Com base nos resultados preliminares, ajustes foram feitos no pipeline de treinamento para melhorar a performance. Entre os ajustes realizados, destacam-se:

1. **Otimização da Filtragem Colaborativa (CF):** Utilização de métricas de similaridade mais robustas, como a correlação de Pearson, para melhorar a identificação de usuários com gostos semelhantes.
2. **Aprimoramento da Engenharia de Características:** Inclusão de variáveis relevantes, como localização geográfica e tempo de espera, para enriquecer os perfis de usuários e restaurantes.
3. **Ajuste de Pesos no Sistema Híbrido:** Modificação dos pesos atribuídos a cada técnica (CBF e CF), baseados nas características do usuário (novo ou com histórico) para determinar a combinação ideal.

3.9 Implantação e Monitoramento Após as melhorias, o sistema de recomendação foi preparado para implantação, com a capacidade de fornecer recomendações personalizadas em tempo real. O monitoramento contínuo será necessário para verificar o desempenho e realizar ajustes futuros.

4 – RESULTADOS E DISCUSSÃO

Esta seção detalha os resultados obtidos após a execução do pipeline de dados e do algoritmo de recomendação desenvolvido. A validação do sistema foi realizada através da análise qualitativa das recomendações geradas para perfis de usuários aleatórios e da verificação da consistência dos dados processados.

4.1. Eficácia do Pré-processamento e Enriquecimento

A etapa de pré-processamento, detalhada na metodologia, provou-se fundamental para a qualidade dos resultados. A limpeza da coluna tags, que transformou strings desorganizadas em listas estruturadas (ex: remoção de códigos de marketing), permitiu que o MultiLabelBinarizer criasse vetores de características densos e representativos.

Além disso, o tratamento dos valores de rating (convertendo valores inválidos para NaN) evitou distorções no cálculo de qualidade dos restaurantes. O enriquecimento com dados do IBGE garantiu que as recomendações fossem geograficamente coerentes, associando corretamente os restaurantes às suas cidades.

4.2. Análise de Caso de Recomendação

O algoritmo operou calculando a Similaridade de Cosseno entre o vetor do perfil do usuário (construído a partir de preferências declaradas como Categoria_Preferida e Preferencia_Gasto) e os vetores dos restaurantes.

Ao executar o script de recomendação (recomendar.py), observou-se o seguinte comportamento padrão:

1. **Aderência à Categoria:** Para um usuário com preferência declarada por "Lanches", o sistema priorizou restaurantes dessa categoria ou com tags correlatas (ex: hambúrguer, sanduíche), validando a capacidade do modelo de filtrar pelo conteúdo semântico.
2. **Ordenação por Similaridade:** A coluna similarity_score gerada pelo modelo serviu como um indicador confiável de relevância. Os itens no topo da lista (Top-10) apresentaram scores mais altos, combinando não apenas a categoria, mas também a proximidade dos vetores de preço e distância.

3. Mitigação do Cold Start: Conforme previsto por Aggarwal (2016), a abordagem baseada em conteúdo implementada conseguiu gerar recomendações válidas mesmo para usuários sem histórico prévio de pedidos, baseando-se apenas nas preferências cadastradas no perfil do usuário (users_data.csv).

4.3. Pontos Positivos e Limitações Observadas

A análise crítica dos resultados revelou pontos fortes e áreas de melhoria:

Pontos Positivos:

- Interpretabilidade: É possível entender claramente por que um restaurante foi recomendado (similaridade de tags e categoria), o que aumenta a confiança no sistema.
- Robustez a Novos Itens: Novos restaurantes cadastrados na base, desde que possuam tags e categoria preenchidas, são imediatamente recomendáveis, sem sofrer do problema de cold start de item.

Limitações (Pontos Negativos):

- Superespecialização: O modelo tende a manter o usuário dentro de sua "zona de conforto" (ex: recomendando apenas o que ele já disse que gosta), confirmando o risco de criação de "bolhas de filtro" (filter bubbles) alertado por Jannach et al. (2025).
- Dependência de Metadados: A qualidade da recomendação é diretamente proporcional à qualidade das tags e dados cadastrais. Restaurantes com dados pobres (poucas tags) tendem a ser penalizados no ranqueamento vetorial.

5 – Conclusão e Trabalhos futuros

5.1. Conclusões

Este projeto atingiu seu objetivo geral de desenvolver um protótipo funcional de sistema de recomendação utilizando dados reais da plataforma iFood. A implementação focou na estruturação de uma arquitetura capaz de processar grandes volumes de dados (406.399 registros) e transformar características textuais e numéricas em representações vetoriais complexas.

Conclui-se que a abordagem implementada foi eficaz para resolver o problema de escolha do consumidor, oferecendo sugestões personalizadas que respeitam restrições de distância e preferências de preço. O sistema alinha-se aos princípios de Sistemas de Recomendação modernos, utilizando técnicas de Engenharia de Atributos (Feature Engineering) e métricas de similaridade para conectar oferta e demanda de forma inteligente. Ademais, o projeto contribui indiretamente para o ODS 8 (Crescimento Econômico), ao dar visibilidade a restaurantes baseando-se na qualidade de seus dados e não apenas em sua popularidade.

5.2. Trabalhos Futuros

Para evoluir este protótipo em direção a um produto comercial robusto e superar as limitações identificadas, propõem-se os seguintes passos, alinhados com a fronteira da pesquisa em IA:

1. Implementação de Aprendizado por Reforço (RL): Conforme anotado no roteiro de desenvolvimento do código fonte, o próximo passo é evoluir de um modelo estático para um agente inteligente que "aprende" com o feedback do usuário (cliques e pedidos), otimizando a estratégia de recomendação dinamicamente ao longo do tempo.

2. Integração de LLMs (Large Language Models): Utilizar LLMs para interpretar as tags de forma semântica e gerar explicações textuais para as recomendações (ex: "Recomendamos este prato pois combina com seu gosto por comida apimentada"), seguindo as tendências apontadas por Mohbat e Zaki (2025).
3. Abordagem Híbrida Completa: Incorporar uma camada de Filtragem Colaborativa pura (fatoração de matrizes) para capturar padrões comportamentais latentes e promover a serendipidade, cruzando dados de múltiplos usuários para diversificar as sugestões e romper eventuais bolhas de filtro.



Repositório do Github

Endereço para o repositório: [ClayTown-ai/Projeto-Aplicado-III](https://github.com/ClayTown-ai/Projeto-Aplicado-III)